

梅见 AI 品牌洞察系统

决赛升级作战手册

从定制 Demo 到可迁移市场证据决策系统的十日验证计划

核心差异化机制：品牌方向五道压力测试

项目定位	当前判断	十日目标	最终验收
内部升级与执行蓝图	工程骨架较完整，数据与验证不足	达到竞赛验证级 5/5	真实数据、真实运行、真实验证、可迁移

00 决策摘要

先把目标、差距和胜负条件放在同一页

一句话任务

用不少于 200 条真实语料、可追溯 RAG 证据链、人工决策与用户验证，把梅见定制 Demo 升级为一套可运行、可验证、可迁移的市场证据决策系统。

为什么必须升级

当前 40 条混合语料不足以支持决赛级判断，模拟语料和预设洞察存在结论污染风险。

十天主战场

数据可信度、证据与反例、AI 稳定性、飞书闭环、真实用户验证、第二案例迁移。

技术新增

加入 Embedding、向量库与 RAG，但只用于语义召回、证据检索和增量判断，不用于技术

品牌原则

“刚好一杯”降级为候选方向，必须与其他候选方向接受同一套证据和用户验证。

范围控制

完整跑通品牌方向模块；市场分析、新品方向和客服洞察只证明共用底层与模块接口。

胜负标准

评委能够亲自看到数据进入、洞察生成、证据核查、人工决策、验证反馈和版本修订。

核心差异化机制

每个候选品牌方向必须通过证据充分性、反例压力、品牌独占、产品承接和增量稳定五道测试；通过后才进入真实用户验证。

内部目标不是“页面更多”，而是“每个高分主张都有可核验成果”。

01 目标定义：竞赛验证级 5/5

区分十天可完成的竞赛验证与长期企业生产级能力

竞赛验证级 5/5

真实数据已跑通；关键指标有测试；失败案例被记录；人工边界清楚；第二案例证明迁移

企业生产级 5/5

真实业务持续运行；权限、安全、监控、SLA、成本与商业结果经过长期验证。十天内不能诚实承诺。

能力层	竞赛验证级 5/5 验收口径
数据层	≥200 条真实有效语料；100% 来源；发现集/验证集分离；模拟语料不参与品牌结论。
分析层	50 条人工标准集；AI 与人工一致性、三次运行稳定性、错误类型和修正规则。
叙事生成	盲跑多个候选；每个方向绑定支持、反对和例外；最终方向经人工与用户验证。
反模板	≥60 条测试语句；同时测模板识别、有效表达保护、误判和漏判。
证据 / RAG	所有关键结论可回溯；Top-5 证据相关率经过人工评测；无法召回时有降级策略。
迁移	第二个非酒类快消案例仅更换配置即可运行；再完成一个跨任务最小测试。
业务闭环	新评论进入后能触发匹配、人工审核、方向修订与版本留档。
产品	在线与 Replay 可用；异常处理、导出、测试、演示录像和断网备用路径完整。

不可偷换概念

“架构可迁移到整个市场”是设计目标；十天内能够证明的是跨品牌与跨任务的初步推广条件，而不是已经适用于所有行业。

02 评分规则与企业真实偏好

把官方评分表和全量企业评语转成内部产品要求

评分项	权重	官方关注	本项目高分动作
AI 应用创新性	30%	切入是否新颖；AI 是否突破生成文案；是否有原创 Agent / Prompt / 工作流。	证据压力测试、RAG 反例检索、候选比较、人机决策。
业务价值	30%	是否回应真实痛点；效率、成本、质量或收入；价值能否验证。	人工基线对照、处理时间、证据完整率、用户验证。
AI 应用深度	20%	是否进入核心链路；工作流复杂度与鲁棒性；飞书 AI 深度。	数据到决策的完整链路、人工审核、回退、Replay、飞书写回。
完整度与推广性	20%	问题到迭代是否闭环；企业内可落地；同行业及跨行业迁移。	梅见全案例、第二品牌、跨任务小测试、十日实施与风险边界。

层级	企业真正看什么	高分方案的表现 / 我们的执行口径
准入	准确命中企业真实问题	不讲通用 AI，说明现有品牌研究在哪一步失真。
核心	小场景真实跑通	用 ≥200 条真实语料完成一次端到端运行。
核心	可信、可控	来源、反例、人工审核、回退、版本记录。
核心	形成业务闭环	新数据进入后影响决策，而不是只输出一次报告。
加分	真实交付物	飞书库、Demo、测试集、报告、视频、代码仓库。
加分	经营价值	量化研究效率、判断质量和内容试错成本。
加分	复制能力	一个跨品牌案例 + 一个跨任务最小案例。
加分	独立判断	重新定义问题，保留否决方向，不顺从行业模板。

03 高分队伍拆解：企业为什么给高评价

来源：用户汇总的全量入围队伍企业评语；本表只提取可复用方法，不复制不可比数字

企业 / 队伍	企业评价中的高分证据	可学习的方法	梅见项目必须采取的动作
新石器 千车算力团	单周处理 1710 条业务单据，闭环率 92.4%；唯一从方案验证进入实际投产。	企业最信任真实运行和量化结果。	用 ≥200 条真实语料跑完闭环；记录处理时长、有效率、证据覆盖和增量修订。
新石器 石听未来	个案闭环 + 改进闭环；P0/P1 硬规则；风险只能上调；人工审核；四周旁路验证。	克制、治理和不重复建设提升企业可信度。	设置置信度分级、强制人工关口、错误回退和 Replay；明确不替代品牌负责人。
瑞幸 好运来队	以四个平台 320 次预实验识别真实问题，并把 Agent 推荐权做成可测量、可迭代方案。	先实验再定义问题，数据不是装饰。	在最终方向前完成保留集、基线对照和用户验证；公开方向被修正的证据。
安克 对对队	210 条真实评论与睡眠声学、人体工程定量交叉印证，明确最大未知风险。	跨证据验证比单纯增加评论更有说服力。	把用户评论与产品事实、竞品事实、场景事实分层；每个方向标注最大未知风险。
星迈 P.R.O.	262 周 Google Trends + 675 条评论，提出 Pool Readiness 新标准，跳出参数内卷。	高分创新来自重新定义评价标准。	尝试从用户冲突推导新的“轻饮关系评价标准”，而非只换一句主张。
书亦 零壹	飞书智能伙伴、表单、消息卡深度整合；听见到学习六段闭环；8 周 MVP 有量化目标。	飞书必须成为业务流程，不是附件。	用多维表格管理原始语料、审核、验证和版本；至少跑通一条自动化或 Aily 交互链路。
超聚变 讯标雷达	每条核心内容绑定原文、来源和附件；无证据不补写。	证据契约直接提升可信度。	系统级规则：没有 evidence_id 的洞察不得进入候选方向和导出报告。

03 高分队伍拆解：从方法论到工程治理

第二组案例聚焦命题重定义、证据压力测试、Agent Harness 与可控演进

企业 / 队伍	企业评价中的高分证据	可学习的方法	梅见项目必须采取的动作
上汽 见微知乘	不追求更多数据或更强模型，直击洞察可靠性，提出证据压力测试。	创新可以发生在判断机制，而不是模型参数。	每个品牌方向都做证据压力测试：反例、替代解释、竞品替换、产品承接失败。
逸仙 三枚美妆蛋	将“分析社媒声量”重定义为“识别消费者需求与产品力错位”。	重新定义问题比机械答题更有记忆点。	把梅见命题重定义为：如何让品类第一心智转化为被真实需求验证的必选理由。
迈金 柯南队	可追溯证据链、事件图谱、公开反馈编码、机会矩阵、验证实验；主动保留反例。	证据不仅支持结论，也必须约束结论。	建立洞察—证据—假设—验证动作关联表；反例单独进入风险评分。
迈金 RidePulse AI	需求证据卡连接用户原声、标签、根因假设和验证动作；双人标注与分歧仲裁。	数据质量治理本身是核心 AI 能力。	至少 50 条双人标注；记录分歧、仲裁结论和标签规范版本。
Polymaker XwX	区分硬约束、偏好、推断和未知；提供规则测试、决策回放和对抗输入验证。	成熟 Agent 不是会说话，而是边界、测试和回放完整。	把产品事实设为硬约束；用户偏好、AI 推断和未知分别标识；增加对抗语料测试。
诺禾 至臻队	全场唯一三项满分；独立 Reviewer、三级风险审批、审核—回归—灰度—上线。	企业级 AI 的重点是受控演进。	设置分析复核人、品牌决策人、发布审批人；新增 Prompt 或规则必须先回归测试。
高途 智排引擎	确定性约束与 AI 交互解耦；规则校验、候选比较、人工确认、审计和回滚。	确定性规则与生成式 AI 各做擅长的事。	来源校验、禁用词和字段完整性用规则；洞察与假设生成用 LLM；版本支持回滚。

高分案例的共同规律

评委不奖励“功能数量”，而奖励真实数据、真实运行、可靠治理、可追溯证据、业务闭环、飞书整合和边界克制。我们的升级路线必须让每一项都有交付物。

04 把企业偏好转成十项硬任务

所有任务必须有成果、有指标、有演示位置

编号	硬任务	完成定义	必须留下的证据
A1	真实数据扩容	≥240 条原始、≥200 条有效、100% 来源；模拟数据仅测试。	数据包 + 采集日志
A2	问题再定义	用企业语言重写真实瓶颈，不让通用平台抢走梅见主角。	一页问题定义
A3	五道压力测试	RAG 组织正反证据，执行证据、反例、独占、产品和增量五项测试。	压力测试报告 + 检索评测
A4	AI 质量验证	标准集、一致性、稳定性、误判、失败案例。	测试报告
A5	候选方向机制	7-10 个候选 → 3 个方向 → 1 个决策；保留淘汰理由。	机会矩阵
A6	人机治理	置信度、人工审核、风险升级、回退与版本审计。	决策日志
A7	飞书闭环	数据、审核、反馈、版本均进入多维表格或 Aily 工作流。	可运行飞书链路
A8	真实验证	15-20 名法定饮酒年龄用户；保留集与增量评论验证。	验证报告
A9	迁移证明	第二非酒类品牌完整小案例 + 一个跨任务最小案例。	迁移报告
A10	量化价值	人工基线与系统对照；测时间、证据率、错误拦截和方向修订。	价值看板

主次原则

梅见完整验证占 70%；通用底层与迁移证明占 30%。任何通用能力都必须先解释它如何改善梅见的品牌判断。

技术原则

RAG 可以增加，模型训练不列入十日主路径。200 条评论不足以支持有说服力的模型训练；Embedding 检索、聚类、规则评测与工作流治理更符合高分企业偏好。

05 当前能力严格审计

基于现有 40 条样本、飞书 / Excel 洞察库、Streamlit Demo、GitHub 与品牌全案

能力层	已有资产	当前 /5	关键缺口	竞赛 5/5 验收
原始数据	40 条，含改写与模拟	1.0	数量不足；来源治理弱；模拟与真实混用。	≥200 条真实有效；完整来源；版本化。
样本设计	覆盖梅见、竞品和饮酒情绪	1.0	缺少采样框、配额、保留集和偏差说明。	预注册采样矩阵；20%-25% 保留验证集。
单条分析	需求、情绪、冲突、顾虑输出	3.0	无人工标准集、稳定性和错误分析。	50 条标准集；三次运行；错误分类。
全量洞察	候选生成与评分流程已存在	2.5	评分有效性未证；可能继承预设结论。	原始语料盲跑；反例检索；人工决策。
叙事生成	可输出品牌主张和内容母题	2.0	“刚好一杯”等结论先于验证。	多个候选接受同一证据压力测试。
反模板	规则词库与语义追问	3.0	缺少误判、漏判和风险基准集。	≥60 条测试集；记录精确率与召回问题。
证据回溯	编号、Replay、导出框架	3.0	来源链不完整；缺少语义检索评测。	RAG + evidence_id；100% 关键结论可回溯。
飞书整合	多维表格数据沉淀	2.0	飞书尚未成为审核与反馈闭环。	至少跑通一条自动化 / Aily / 审核写回。
迁移	方法论层面可迁移	1.0	无第二案例；核心仍有梅见硬编码。	跨品牌 config-only 迁移 + 跨任务测试。
业务闭环	有报告与全案	1.0	没有执行、验证、反馈再学习记录。	完成一次方向修订并保存版本。



06 改善优先级与资源边界

先补可信用，再补迁移，最后补视觉与扩展功能

级别	含义	任务范围	时间	管理规则
P0	不解决就无法建立可信用	真实数据、原始/结论分离、采样规则、保留集、证据与反例、人工审核。	第 1-6 天	不可延期
P1	决定能否形成高分差异	RAG、AI 评测、用户验证、飞书闭环、第二品牌、价值对照。	第 4-9 天	可缩范围，不可取消
P2	提升展示完成度	视觉优化、更多模块页面、动画、高级模型、更多行业案例。	第 9-10 天	必要时删除

完整交付

品牌方向发现模块：真实数据、RAG、候选比较、人工决策、验证与版本回流。

最小证明

市场分析、新品方向、客服洞察：共用底层、配置接口和一个跨任务样例。

明确不做

大规模爬虫平台、模型训练、企业级权限系统、全行业生产部署承诺。

停止条件

如果第 4 天仍未得到 ≥200 条有效真实语料，立即缩减第二案例规模与视觉工作；不得用模拟语料补足品牌证据。

07 目标系统：市场证据决策底层

通用能力不输出统一答案，而是把不同市场问题转成可审计的决策过程



架构层	定义
不变底层	证据对象、向量检索、结构化分析、假设评分、人工审核、版本回放。
行业配置	行业词典、品牌资产、竞品集合、合规边界、评价权重。
业务模块	品牌方向、市场分析、新品方向、客服洞察与转化支持。
输出变化	品牌叙事、机会矩阵、新品 Brief、客服策略、验证任务。



08 核心差异化机制：品牌方向五道压力测试

别人用 AI 生成方向；本系统要求 AI 先证明方向是否值得相信

压力测试	核心追问	系统输出	硬性判定
01 证据充分性	这个方向由哪些真实语料支持？来源是否完整？证据是否只是重复表达？	支持证据包、来源分布、证据缺口	无 evidence_id 的结论直接失败
02 反例压力	哪些评论无法解释、直接反对或提示另一种原因？	反例清单、例外人群、替代解释	不得隐藏反例；风险只能上调
03 品牌独占	把“梅见”替换成 RIO、CHOYA 或十七光年后，表达是否仍然成立？	竞品替换结果、梅见独有资产	可被普遍替换则扣分或淘汰
04 产品承接	梅见的口味、度数、喝法、包装、价格和渠道能否兑现这个承诺？	硬约束冲突、体验改造要求	产品事实不支持则不得只靠传播补救
05 增量稳定	保留集或新评论进入后，方向被支持、修正、形成新候选还是被推翻？	增量分类、分数变化、版本差异	必须保留修订和回滚记录

规则	定义
单项评分	每项 0-5 分；必须同时显示依据、反例和置信度。
硬门槛	证据充分性与产品承接均不得低于 3 分，否则不能进入用户验证。
进入验证	五项总分达到 18/25，且没有硬门槛失败，才进入 15-20 人真实用户验证。
最终输出	压力测试雷达、证据包、失败项、修改建议、版本号、人工决定。

Demo 必演示

至少展示一个看似正确的方向，因为反例、竞品替换或产品事实而被降分、修正或淘汰。

最终记忆点

AI 的价值不是让方案更漂亮，而是让未经证据验证的品牌判断更难进入市场。

09 技术架构：飞书数据底座 + RAG 证据检索 + 人机决策

每种技术只解决它擅长的问题；RAG 为五道压力测试提供证据

组件	职责	边界
飞书多维表格	原始数据、人工标注、审核状态、验证结果、版本记录	业务唯一事实源
Embedding	把评论和证据片段转换为语义向量	语义检索，不等于结论
Chroma / FAISS	存储向量及 evidence_id、品牌、场景、来源元数据	演示检索索引，可重建
RAG	为洞察和候选方向检索支持、反对、例外证据	无证据不生成
规则引擎	字段完整性、来源约束、禁用词、风险等级、版本一致性	确定性检查
LLM	单条结构化分析、冲突概括、候选假设、表达审查	生成与推理
人工审核	证据抽检、候选选择、风险升级、最终品牌决策	责任主体
Streamlit / Replay	展示、对比、审计、导出与断网演示	竞赛体验层



训练策略

本阶段不训练大模型。若需要模型能力证明，优先完成 Embedding 检索评测、标签一致性评测和 Prompt 回归测试；这些比用 200 条数据微调更可靠。

10 数据升级方案

目标：收集 240-300 条，清洗后保留不少于 200 条真实有效语料

语料类型	目标数	覆盖重点	研究作用
梅见直接反馈	70	口味、喝法、包装、购买、场景、正负反馈	检验产品事实与品牌资产
RIO / CHOYA / 十七光年	75	每品牌约 25 条，覆盖选择理由、差评与替代关系	形成可比竞品证据
低度酒饮酒态度	50	酒味、微醺、失控、拒酒、自主选择、饮后负担	识别跨品牌情绪冲突
消费场景	45	独处、朋友小聚、佐餐、家庭局、礼赠、便利店调饮	判断场景规模与边界

数据表	字段核心	管理原则
raw_evidence	原文、平台、链接、日期、对象、互动量、采集方式	只保存事实，不提前写品牌洞察
annotation	需求、情绪、冲突、顾虑、场景、标注人、置信度	人工与 AI 输出分开
hypothesis_evidence	假设、支持 / 反对 / 例外、evidence_id、理由	约束候选方向
decision	候选评分、人工决定、否决理由、版本	保留品牌责任主体
experiment	测试对象、反馈、结果、修订动作	形成验证回流

发现集

160-180 条，用于形成冲突、候选洞察和品牌机会。

保留验证集

40-60 条，方向形成前不得输入系统，用于检测结论能否解释新语料。

11 AI质量与RAG评测

有测试结果，才能把“AI 能力”变成竞赛证据

测试对象	测试集	指标	通过标准
结构输出	50 条人工标准集	字段有效率、缺失率、格式错误率	有效 JSON 100%；错误有降级
语义标注	双人标注 + 仲裁	关键字段一致率、分歧类型	目标 ≥80%，最终填实测
运行稳定性	同一批数据运行 3 次	核心冲突与证据集合重合度	目标 ≥85%，最终填实测
RAG 召回	30 个检索问题	Top-5 相关率、漏召、错召	目标 ≥80%，最终填实测
证据忠实度	抽检所有核心结论	是否可由原文支持	关键结论 100% 有 evidence_id
反模板	30 条模板 + 30 条有效表达	误判、漏判、风险追问	有效表达不能被一刀切
增量判断	方向冻结后输入 20-30 条新评论	支持 / 修正 / 新候选 / 无关分类	至少展示一次真实修订

失败类型	系统行为	治理规则
来源不足	停止生成，提示补充证据	不得用常识补写
证据冲突	同时展示正反证据，降低置信度	交给人工选择
检索失败	关键词 / 元数据过滤降级	记录失败日志
LLM 格式错误	Pydantic 校验、重试、离线 Replay	不中断主流程
品牌硬约束冲突	风险等级上调	不得由 AI 自动下调

12 梅见候选叙事压力测试实战

系统不能把策划者的答案藏进数据里；候选方向必须逐项过五关

重新起跑规则

删除输入数据中的“可转化品牌洞察”和预设品牌方向；“刚好一杯”只作为候选之一，和其他方向接受完全相同的评分与验证。

步骤	分析对象	必须输出
1 市场事实	低度酒、竞品、跨界替代和瓶子星球业务要求	明确梅见必须解决的业务问题
2 产品事实	口味、甜度、上头、喝法、包装、价格和渠道	避免叙事超出产品承接能力
3 用户结构	独处、朋友小聚、佐餐、家庭局、拒酒与轻饮人群	判断主场景及非目标人群
4 冲突聚类	想要 / 拒绝、情绪、身份、关系、体验负担	形成可验证冲突结构
5 候选机会	先生成 7-10 个，再筛至 3 个	避免单一答案锁定
6 五道压力	证据、反例、品牌独占、产品承接、增量稳定	暴露方向脆弱点并形成雷达评分
7 人工决策	品牌适配、差异、可执行、风险和长期资产	由人选择或重组方向
8 用户验证	15-20 名法定饮酒年龄用户 + 保留语料	修正命名、场景和表达
9 全案输出	世界观、人群、冲突、角色、主张、场景、内容与体验	形成最终梅见品牌全案

只有当“刚好一杯”在证据、竞品、产品、用户和执行五个维度都优于其他方向时，它才能成为最终主张。

13 飞书原生业务闭环

从素材库升级为可运行的审核、决策和反馈系统

环节	飞书载体	系统动作	责任人
语料进入	多维表格 / 表单	生成 evidence_id，校验来源与重复	wth
AI 分析	AI 字段 / Aily / API workflow	输出结构标签、置信度和证据引用	wth
人工审核	审核字段 / 消息卡	确认、修改、驳回、风险上调	wph
候选决策	机会矩阵	比较候选、记录淘汰理由	wph
市场验证	表单 / 访谈记录	记录反馈、样本与结论	wph
版本回流	自动化 + 版本表	更新方向版本和证据指纹	wph
报告输出	飞书文档 / Markdown	生成可追溯报告和演示入口	wth



最低飞书验收

至少完成一条真实链路：新评论进入多维表格 → 自动分析 → 人工审核 → 结果写回 → Demo / 报告读取。只展示表格截图不计为闭环。

14 迁移能力验证

五道压力测试保持不变；行业证据、竞品和产品硬约束随品牌配置

验证层	建议对象	数据规模	深度	证明内容
案例 A	梅见品牌方向	≥200 条	完整闭环	底层系统的主验证
案例 B	非酒类快消品牌	50-80 条	完整小案例	只更换品牌配置、行业词典和评分权重
案例 C	新品机会或客服洞察	20-30 条	跨任务烟雾测试	复用 Evidence / Insight / Decision 对象

通过维度	验收条件
代码复用	核心分析、RAG、证据与决策模块不改；允许更换配置和 Prompt 模板。
输出差异	第二案例必须产生与梅见明显不同的冲突、机会和评价维度。
边界诚实	结论表述为“具备跨品牌 / 跨任务推广条件”，不声称已经覆盖全部行业。
失败价值	如果迁移失败，必须记录硬编码点并形成架构修订，不隐藏失败。

第二案例选择原则

数据公开、用户评论充足、产品逻辑与酒类明显不同、十天内能够理解。优先考虑即饮咖啡、个护或零食，不建议再选另一款低度酒。

15 十日实施路径

2026-08-04 至 2026-08-13 完成核心建设，8 月 14-15 日只做交付与终检

日期	主任务	当日交付	决策门
D1 8/4	范围冻结	数据字典、采样矩阵、测试指标、第二案例、角色分工	规则未定前不批量采集
D2 8/5	数据 + RAG	累计 120 条；向量索引原型；字段映射	当天抽查来源完整性
D3 8/6	数据 + RAG	累计 240-300 条；Top-K 检索初测	不足则增加来源，不用模拟补足
D4 8/7	清洗与分组	≥200 条有效；去重；发现 / 验证集；模拟隔离	形成数据质量报告
D5 8/8	标准集	50 条双人标注；60 条反模板集；人工基线	完成分歧仲裁
D6 8/9	全量重跑	RAG 证据包；7-10 个候选；稳定性测试	不得提前选“刚好一杯”
D7 8/10	五道压力测试	3 个候选的压力测试雷达、失败项、淘汰理由	至少一个方向被降分或淘汰
D8 8/11	市场验证	15-20 人用户测试；20-30 条增量语料	至少形成一次真实修订
D9 8/12	迁移验证	第二品牌小案例；跨任务烟雾测试	记录未复用部分
D10 8/13	冻结交付	飞书闭环、Demo 测试、价值测算、最终全案	功能与数据冻结
8/14	演示包装	3-5 分钟视频、正文、二维码、备用 Replay	不新增核心功能
8/15	终检提交	权限、链接、无痕访问、PDF 与飞书文档	完成预提交
8/16	缓冲	只处理提交故障	不改核心结论

关键路径

D4 有效数据 → D5 标准集 → D6 盲跑候选 → D7 五道压力测试 → D8 用户验证。任何一天延误都会直接压缩第二案例和视觉优化时间。

16 并行 workflows 与会议节奏

避免所有任务串行等待技术完成

工作流	职责	周期	交付
数据研究	采集、清洗、来源、标注、用户验证	D1-D8	有效语料、标准集、验证报告
AI / 工程	RAG、结构化输出、测试、Replay、导出	D1-D10	可运行 Demo、测试报告
品牌策略	命题诊断、候选评价、产品与竞品约束、全案	D1-D10	机会矩阵、最终叙事
飞书闭环	多维表格、自动化、审核状态、写回	D3-D10	真实业务链路
交付表达	文档、图表、视频、权限、演示脚本	D7-D15	完整提交包

节点	议题	输出规则
每日 10 分钟	数据量、阻塞、当天决策门	不讨论长期功能
D4 数据评审	有效样本、偏差、验证集、是否继续扩充	数据负责人签字
D7 压力测试会	3 个候选、五项雷达、失败项、淘汰与修正	品牌负责人签字
D10 冻结会	验收表、Demo、文档、风险与备用路径	禁止新增需求

会议原则

每次会议只作决定，不重新发散。所有决定写入 Decision Log：决定内容、依据、反例、负责人、下次复核时间。

17 评分映射与最终验收

任何评分主张都必须指向一个评委可看到的证据

评分项	高分能力	评委可见证据	目标
AI 创新 30%	五道压力测试；RAG 正反例检索；增量判断；候选方向比较	压力测试雷达 + Demo + RAG 测试	5/5
业务价值 30%	真实品牌问题；人工基线；用户验证；方向修订	价值看板 + 用户验证报告 + 全案	5/5
AI 深度 20%	数据—检索—分析—审核—验证—回流；飞书原生链路	架构图 + 操作录像 + 流程日志	5/5
完整与推广 20%	梅见全案例；第二品牌；跨任务测试；风险与实施路径	迁移报告 + 十日交付 + 边界声明	5/5

验收域	完成标准	状态
数据	≥200 条真实有效；100% 来源；模拟隔离；保留集；数据质量报告	☐
研究	50 条双人标注；分歧仲裁；15-20 人用户验证	☐
AI	结构、稳定性、RAG、反模板、增量判断五类测试	☐
品牌	3 个候选、五道压力测试、至少一次淘汰或修正、最终决策、完整全案	☐
飞书	一条真实自动化 / Aily / 审核写回闭环	☐
迁移	第二品牌 + 跨任务小测试	☐
工程	在线、Replay、异常处理、导出、测试、录像	☐
交付	飞书文档、PDF、Demo、GitHub、视频、无痕权限测试	☐

18 业务价值测量

不预写收入增长，先量化研究效率、证据质量和决策风险

价值维度	对照实验	指标	目标口径
研究效率	同一批 50 条评论：人工分析 vs 系统分析	总耗时、人均耗时、返工时间	实测后填写
证据质量	抽检所有核心洞察和品牌结论	可追溯率、无证据结论数	关键结论 100% 可追溯
分析质量	人工标准集与三次重复运行	一致率、稳定性、错误类型	达到内部通过线
风险控制	反模板与对抗测试	误判、漏判、风险拦截数	展示成功与失败样例
决策质量	候选方向会与用户验证	被否决方向、修订次数、修订依据	至少一次证据驱动修订
推广成本	第二品牌和跨任务迁移	修改代码量、配置时间、不可复用点	核心流程不修改

可承诺

更快整理证据、更完整回溯来源、更早发现模板和风险、更规范比较候选方向。

暂不承诺

销售收入增长、品牌份额变化、用户偏好长期提升。除非完成真实市场投放与长期追踪。

企业评语反复奖励的是“能被验证的价值”，而不是漂亮但无法核验的收益预测。

19 风险、边界与止损

主动暴露风险会增加企业可信度

风险	表现	控制动作	优先级
评论样本偏差	平台用户不等于全部消费者	多平台采样、记录配额、保留局限声明	高
结论污染	人工标签提前写入品牌机会	原始数据与洞察分表；盲跑候选	高
RAG 错召	相似语义不等于相同立场	元数据过滤、人工抽检、反例检索	高
AI 幻觉	生成不存在的证据或因果	evidence_id 强校验；无证据不补写	高
方向过度泛化	一批评论推导整个 Z 世代	用户分层、样本边界、保留集和访谈	中
品牌承接不足	叙事超出产品、口味和渠道能力	产品事实硬约束；跨部门建议明确	高
迁移过度承诺	第二案例不能代表全部市场	只声明初步推广条件	中
时间失控	同时开发过多模块	P0 优先；P2 可删除；D10 冻结	高

触发条件	止损动作
D4 有效语料 <200	暂停第二品牌扩容和视觉设计，集中补数据与来源。
RAG Top-5 相关率不达标	降低 RAG 角色，仅用于相似语料展示；核心判断采用规则过滤 + 人工证据包。
用户验证无法招募	启用结构化访谈与小样本盲评，明确样本限制，不伪造数量。
飞书自动化受限	保留多维表格审核状态与人工触发，录制可复现流程。
第二案例迁移失败	提交失败分析和硬编码清单，证明系统能够自我审计。

20 最终交付物与待确认决策

交付物必须共同证明：做了、跑了、测了、改了、能迁移

编号	交付物	内容
D01	真实语料与数据治理包	原始数据、清洗日志、数据字典、标注手册、样本边界
D02	AI 与 RAG 测试报告	标准集、稳定性、召回、反模板、失败案例
D03	梅见品牌机会与压力测试矩阵	候选方向、五项压力评分、证据、反例、失败项、决策与淘汰理由
D04	梅见品牌全案	最终叙事、场景、内容、产品与渠道承接
D05	飞书洞察与审核闭环	多维表格、审核、自动化或 Aily、版本记录
D06	可运行 Demo	在线 / Replay、报告导出、异常路径、测试与操作录像
D07	迁移验证包	第二品牌小案例、跨任务测试、不可复用点
D08	业务价值与用户验证	人工基线、用户反馈、方向修订、价值看板
D09	参赛提交包	飞书文档、PDF、GitHub、Demo、3-5 分钟视频、权限记录

决策点	建议	截止
第二品牌	选择即饮咖啡、个护或零食中的一个	D1 确认
飞书能力	是否具备 Aily 权限；没有则选择自动化 + 多维表格审核	D1 确认
用户验证	招募渠道、法定饮酒年龄确认、15-20 人名单	D2 确认
主张状态	“刚好一杯” 仅为候选，验证前不得写成最终答案	立即生效
团队责任	数据、工程、品牌、飞书、交付五条工作流负责人	D1 确认

21 作战室总看板

每天只更新这张表：完成度、风险和下一决策门

指标	目标	当前基线	状态	决策门
真实有效语料	≥200	40	☐	D4
完整来源覆盖	100%	不完整	☐	D4
双人标注	≥50	0	☐	D5
AI / RAG 测试	5 类测试	未完成	☐	D6
五道压力测试	3 个候选完整评分	未完成	☐	D7
目标用户验证	15-20 人	0	☐	D8
真实方向修订	≥1 次	0	☐	D8
第二品牌	1 个小案例	0	☐	D9
飞书真实闭环	1 条	部分数据底座	☐	D10
在线 / Replay	均可演示	已有骨架	☐	D10
最终提交包	9 项齐全	部分完成	☐	8/15

最终胜负逻辑

高分不是因为我们交了更多文件，而是评委能沿着一条清楚的链路验证：真实问题被重新定义 → 真实数据进入系统 → AI 提出候选 → 五道压力测试主动寻找漏洞 → 人工决策与用户验证推动方向修订 → 飞书形成业务闭环 → 第二案例证明迁移条件。

先把方案跑起来，再让评委看到它为什么可信。

版本：V1.1 | 日期：2026-08-04 | 用途：内部升级与执行，不作为正式参赛方案直接提交